

Dự báo giá nhà TP.HCM từ dữ liệu rao vặt

Thu thập tin rao, trích đặc trưng từ mô tả tự do, chuẩn hoá địa chỉ qua đợt sáp nhập 2025, rồi so sánh 12 mô hình hồi quy trên cùng một bộ fold.

34.607

dòng dữ liệu
sau làm sạch

12

mô hình
chia 4 tầng

6,32–6,66

điểm % MdAPE thấp
hơn baseline môi giới

Thành viên nhóm

Lê Phú Hiếu

26410038 · LT.K2026.1.TTNT

Nguyễn Thanh Duy

26410030 · LT.K2026.1.TTNT

Nguyễn Thanh Phong

26410090 · LT.K2026.1.TTNT

Nguyễn Thị Mai Thi

26410117 · LT.K2026.1.TTNT

Hồ Viết Trịnh

26410140 · LT.K2026.1.TTNT

Nguyễn Ngọc Bích

25730012 · CN1.K2025.1.TTNT

Nguyễn Anh Tài

25730063 · CN1.K2025.1.TTNT

Bài toán

Ước lượng **tổng giá rao** của một bất động sản tại TP.HCM từ hai loại đầu vào:



Thuộc tính có cấu trúc

diện tích, phòng ngủ, số tầng, vị trí, pháp lý



Mô tả tự do của tin rao

phần người bán tự viết, form của sàn không ép khuôn

Mô tả chứa thứ form không có

“hẻm xe hơi”

ô tô vào tận cửa

“nở hậu”

phía sau rộng hơn mặt tiền

“ngộp bank”

chủ kẹt nợ ngân hàng, cần bán gấp

“sổ hồng riêng”

pháp lý tách riêng, rõ ràng

Câu hỏi trung tâm: phần văn bản đó đáng bao nhiêu?

Trả lời ở slide 13 (ablation)

Ba nguồn dữ liệu



Hiện tại

Chợ Tốt

API JSON công khai, quét theo quận

2.326 tin sau làm sạch
từ 2.400 tin thô



Hiện tại

mogi.vn

Parse HTML: trang danh sách → trang chi tiết

334 tin sau làm sạch
từ 360 tin thô



Lịch sử

Hugging Face

Tải parquet bộ
`tinixai/vietnam-real-estates`

31.947 tin sau làm sạch
từ 40.000 tin thô

Ranh giới tự đặt khi thu thập



Tôn trọng robots.txt



Không vượt anti-bot chủ động



1 request mỗi 1,5 giây



Không thu thập thông tin người bán

Xoá số điện thoại ngay lúc ghi file

Người rao né bộ lọc của sàn bằng đủ kiểu:

Chữ số Unicode

😊 Emoji thay chữ số

A Chữ cái thay số

AB ✓ Số viết bằng chữ

🚫 Ký tự vô hình chèn giữa

BƯỚC 1

Văn bản gốc

tin rao đúng như người bán viết

BƯỚC 2

Chuỗi chỉ-để-dò

quy mọi biến thể về chữ số, kèm bản đồ vị trí ngược về văn bản gốc

BƯỚC 3

Xoá đúng đoạn số

chỉ ký tự thuộc số điện thoại bị xoá, phần còn lại giữ nguyên

14

kiểu nguy trang được phủ bằng test

0

số điện thoại sót lại trong kho thô

Trích đặc trưng định lượng từ văn bản

Bảng trường rút bằng regex. Ba luật khó nhất:

TIN RAO VIẾT

BỘ LUẬT HIỂU LÀ

VÌ SAO KHÓ

“1 trệt 2 lầu”

3 tầng

Đếm tầng bằng phép cộng. Tiếng Việt gọi tên từng thành phần: trệt + 2 lầu = 3 tầng.

“4x15”

60 m² · mặt tiền 4 m

Kích thước, không phải diện tích. Phải nhân ra, và chiều ngang chính là mặt tiền.

“nhà mặt tiền”
“mặt tiền 4m”

vị trí ≠ số đo

Cùng chữ, khác trường. Một cụm là loại vị trí, cụm kia là số đo mặt tiền.

Đo chất lượng bằng nhãn độc lập



Nhãn không do LLM gán

Lấy từ chính trường có cấu trúc người bán điền vào form, thứ bộ luật regex không hề nhìn thấy.


Bộ nhãn vàng: 200 tin ngẫu nhiên (seed 42) từ kho thô Chợ Tốt

13/17

**lỗi còn lại của trường số tầng
lệch đúng 1 đơn vị**

Tin viết “1 trệt 1 lầu” nhưng điền số 1 vào form. **Nhiều của nhãn, không phải bộ luật đọc sai.**

F1 theo trường



Trục ngang bắt đầu từ 0,70 để thấy rõ khoảng cách tới chỉ tiêu.

Sáp nhập hành chính 2025

168

đơn vị cấp xã của TP.HCM từ 01/07/2025

113 phường



54 xã

1 đặc khu

Cùng một khu, hai cái tên

Tin 2026 ghi phường mới, dữ liệu lịch sử ghi phường cũ.

Bảng ánh xạ dựng từ chính dữ liệu



Minh họa: nhiều phường cũ gộp vào một phường mới

14/16

phường mới gộp từ nhiều phường cũ

0,45

tỷ lệ đa số thấp nhất: phường cũ đông tin nhất chỉ chiếm 45%

Chống rò rỉ nhãn: kiểm, không tin

☑️☑️☑️ Danh sách kiểm chạy trước **mỗi** lần huấn luyện. Nó bắt được hai lỗi thật:

Lỗi 1

Bước tách từ tái tạo cụm tiền

5,85 tỷ

bỏ dấu phẩy

"585" + "tỷ"

Tiền đã lọc khỏi mô tả, nhưng bỏ dấu phẩy thập phân biến "5,85" thành "585" nằm cạnh chữ "tỷ" còn sót.

Lỗi 2

Đơn giá lọt qua bộ lọc tiền

110 triệu2

× diện tích

= nhãn

Đơn giá dính chữ nên lọt qua dưới dạng "110 triệu2"; nhân với diện tích ra thẳng giá cần dự báo.


0 / 34.607

dòng mang token tiền vào TF-IDF

Pipeline tổng thể



Số dòng qua từng bước làm sạch



Danh mục 12 mô hình, 4 tầng



Baseline môi giới

Trung vị giá/m² theo (quận, phường, loại nhà) nhân diện tích: cách một người môi giới định giá trong đầu.

Thăng Dummy: chỉ chứng minh dữ liệu có tín hiệu.

Thăng baseline môi giới: mới là phần học máy đóng góp.

Kết quả chính (E1)

2.326 tin Chợ Tốt · 5-fold · mỗi ô là trung bình qua 5 fold, MdAPE kèm độ lệch chuẩn

Mô hình	MdAPE (%)	RMSE (tỷ)	R ²
Dummy (trung vị)	34,6 ± 2,1	7,250	-0,053
Trung vị giá/m ² theo nhóm	20,5 ± 1,4	3,802	0,706
Ridge	19,7 ± 0,7	7,002	-0,160
Random Forest	15,1 ± 0,9	4,626	0,579
CatBoost	14,2 ± 1,2	3,857	0,708
LightGBM	13,9 ± 1,2	3,925	0,698
XGBoost	14,0 ± 1,1	3,793	0,716

Ba dòng tô màu cách nhau chưa tới một độ lệch chuẩn giữa các fold, nên bảng không chọn ra một mô hình thắng.

6,32–6,66

điểm phần trăm MdAPE mà nhóm dẫn đầu thấp hơn baseline môi giới

So sánh công bằng

Cùng bộ fold, cùng ngân sách tính chỉnh, cùng seed. Không tuyên bố hơn kém khi hai khoảng trung bình ± độ lệch chuẩn chồng lấn.

Vì sao phải báo cả ba chỉ số

Nhóm tuyến tính: **MdAPE** khá, nhưng **R^2** âm.

	Hồi quy tuyến tính	Ridge	LightGBM
MdAPE (%)	18,8	19,7	13,9
RMSE (tỷ)	10,970 ± 10,006	7,002 ± 2,962	3,925 ± 1,125
R^2	-2,783	-0,160	0,698

Trung bình 5-fold trên 2.326 tin Chợ Tốt (bảng E1)

- 1 Huấn luyện trên log(giá)
- 2 Vài điểm ngoại suy rất xa
- 3 exp phóng đại thành sai số khổng lồ trên thang VND
- 4 **RMSE sụp, trung vị không đổi**

Không phải lỗi cài đặt: đó là cơ chế của phép biến đổi log.



Đọc R^2 một mình → kết luận hồi quy tuyến tính vô dụng. **Sai.**



Đọc MdAPE một mình → kết luận nó ngang boosting. **Cũng sai.**

Ablation: văn bản đáng bao nhiêu?

ĐẶC TRƯNG DÙNG	MDAPE (%)	Δ SO VỚI CHỈ BẢNG
Chỉ đặc trưng bảng	14,77	0,00 (mốc)
Bảng + cờ văn bản thủ công	14,08	-0,69
Bảng + TF-IDF/SVD	13,91	-0,86
Bảng + TF-IDF/SVD + cờ	13,88	-0,89

-0,89

điểm % MdAPE khi thêm
TF-IDF/SVD và cờ văn bản

Cùng bộ fold, cùng mô hình (LightGBM),
cùng ngân sách. Khác biệt duy nhất là
nhánh văn bản.

Đọc đúng cỡ hiệu ứng: độ lệch chuẩn giữa các fold tới 1,19, lớn hơn mức giảm. Bốn cấu hình dùng chung bộ fold nên đây là phép so sánh: một xu hướng nhất quán về dấu, chưa phải con số chốt.

E2: trôi giá theo thời gian

HUẤN LUYỆN

Tin $\leq 06/2025$

31.947 tin, bộ lịch sử



KIỂM TRA


Tin crawl 08/2026

2.326 tin Chợ Tốt

+2,8

điểm % MdAPE: trung vị mức xấu đi khi chuyển giao

CatBoost +0,8 · LightGBM +2,4 · XGBoost +3,1



Nét đứt: khoảng trống dữ liệu 2026-03 → 2026-08. Hình thoi là tin crawl 08/2026 (nguồn B), tròn là bộ lịch sử (nguồn A).




Cả hai phía đều là giá rao, nên không lẫn khoảng cách giá rao / giá giao dịch.



Nhưng hai phía khác sàn: một phần chênh lệch là chênh giữa hai nguồn, không phải trôi giá thuần túy.

Demo: web app dự báo có giải thích



1 Streamlit

nạp đúng artefact mà bước huấn luyện xuất ra

2 Khoảng tham khảo

rộng bằng MdAPE đo trên hold-out (14,2%), không phải con số tự đặt

3 Giải thích từng ca

SHAP waterfall cho biết đặc trưng nào đẩy giá lên, đặc trưng nào kéo xuống

Ví dụ trong ảnh: nhà phố Tân Bình, 60 m², 3 tầng → giá ước lượng 8,04 tỷ, khoảng tham khảo 6,90–9,19 tỷ.

Hạn chế, nói thẳng



Học từ giá rao, không phải giá giao dịch

Nhóm không có dữ liệu để đo khoảng cách đó nên không phỏng đoán.



Chỉ phủ TP.HCM, dày nhất ở ba quận mục tiêu

E3 đo trực tiếp mức suy giảm khi sang phường chưa thấy: MdAPE trung bình $15,2\% \pm 4,1$.



Tin rao tự mâu thuẫn

Form một đăng, mô tả một nẻo. Những tin này nằm ngoài tầm với của mọi bộ luật văn bản.



Số tầng chưa đạt chỉ tiêu F1 0,9

Báo cáo trung thực kèm phân tích lỗi, thay vì chỉnh luật cho khớp nhãn nhiều.

Hướng phát triển



Bổ sung dữ liệu

Crawl script đã resume được, chỉ cần chạy tiếp



Toạ độ và đặc trưng khoảng cách

Đã thiết kế, hoãn theo cut-line



Đối chiếu với giá giao dịch thật

Nếu tiếp cận được dữ liệu giao dịch




Đọc đường cong học

Cho biết crawl thêm còn đáng hay không

Đường cong học (LightGBM)

MdAPE (%) trên cùng tập hold-out, theo số tin huấn luyện



186 → 1.860 tin: MdAPE 22,9% → 14,2%. Bước cuối tăng 0,8 điểm; mỗi tỷ lệ mới chạy một lần nên chưa kết luận được đường cong đã phẳng.

KẾT LUẬN

Ba điều nhóm rút ra

- 1** **Boosting hơn baseline** môi giới 6,32–6,66 điểm % MdAPE. Giá trị của học máy nằm ở khoảng cách này.
- 2** **Mô tả rao vặt có tín hiệu giá:** giảm 0,89 điểm % MdAPE, nhất quán về dấu nhưng nhỏ hơn độ lệch giữa các fold.
- 3** **Dữ liệu cũ mất độ chính xác theo thời gian:** chuyển sang tin 2026, MdAPE xấu đi trung vị 2,8 điểm %.

Cảm ơn thầy cô và các bạn đã lắng nghe

Hỏi đáp

CS106.F31.CN2 · Nhóm 14